

研究论文 · 中文译稿

面向大规模地理空间分析的 多源时空数据立方体

A multi-source spatio-temporal data cube for large-scale geospatial analysis

高帆、岳鹏、曹志鹏、赵帅峰、上官博一、蒋良村、胡磊、方哲、梁哲恒

International Journal of Geographical Information Science, 36(9), 1853-1884 (2022)

DOI: 10.1080/13658816.2022.2087222

说明：本稿为辅助阅读的中文译文。公式、缩写、数据与参考文献请以英文原文为准。

研究文章 面向大规模地理空间分析的多源时空数据立方体 高帆 a, 岳鹏 a,b,c, 曹志鹏 a, 赵帅峰 a, 上官博一, 蒋良村 a, 胡磊 a, 方哲 a 和梁哲恒 d 武汉大学遥感与信息工程学院, 湖北省武汉市; b 地理空间技术协同创新中心, 湖北省武汉市; c 武汉大学湖北省智能地理处理工程中心 (HPECIG), 中国湖北省武汉市; 南方数字科技有限公司, 中国广东省广州市 摘要: 对地观测 (EO) 大数据的数据管理和分析面临着挑战。扩展数据立方体对分析就绪的大规模对地观测数据的日益增长的承诺, 我们提出了一个分层在数据立方体上的新的地理空间基础设施, 以促进大规模对地观测数据的管理和分析。与之前的数据立方体工作相比, 所提出的基础设施 GeoCube 将数据立方体的能力扩展到多源大矢量和栅格数据。

GeoCube 的开发主要包括三个方面: 将多源地理空间数据的立方体维度形式化、沿这些维度处理地理空间数据查询以及组织立方体数据以进行高性能地理处理。该策略改进了 EO 数据立方体的管理, 并与商业智能立方体保持连接, 为 EO 数据立方体的处理提供补充信息。该论文重点介绍了维度形式化在线分析处理、瓦片的分布式立方体对象以及支持数据立方体处理计算强度预测的人工智能方面的主要工作和关键研究贡献。利用来自 Landsat、高分和 OpenStreetMap 的数据进行的案例研究证明了所提议的基础设施的功能和适用性。

文章历史记录 2021 年 7 月 23 日接收 2022 年 6 月 5 日接受 关键词 数据立方体; 高性能计算; 对地观测; 云计算; 人工智能

一、简介

对地观测 (EO) 数据是大数据的主要来源, 包括从轨道传感器、现场测量和模拟模型获取的大规模和多源地理空间数据 (Baumann 等人, 2018 年; Wagemann 等人, 2018 年)。由于对 EO 数据的多数据源集成、高性能处理和多样化应用的需求, EO 数据的管理具有挑战性。这些多源 EO 数据的特点是空间、时间和光谱分辨率的差异、观测条件的变化 (例如不同的大气条件和观察几何形状) 以及不同的空间数据结构 (例如空间数据结构)。

联系方式 Peng Yue pyue@whu.edu.cn © 2022 Informa UK Limited, 以 Taylor & Francis Group 名义经营 《国际地理信息科学杂志》 2022, VOL. 36、NO. 1853 年 9 月 -1884 年 <https://doi.org/10.1080/13658816.2022.2087222>

栅格和矢量数据) (Lewis 等人, 2016)。这些特征使得 EO 数据集成、存储和处理成为一个具有挑战性的课题。信息基础设施的最新进展显示了对地观测数据处理的重大前景 (Yue 等人, 2016 年; Sudmanns 等人, 2019 年) (图 1)。20 世纪 90 年代至 2000 年代, EO 领域发生了几次范式转变。在本地处理范式中, EO 数据通常从数据门户下载并在本地机器中处理。这可能会导致较高的网络带宽资源和时间成本。由于本地存储空间和计算能力不足, 用户解决大规模地理空间问题的能力受到限制 (Wulder and Coops 2014, Kopp et al. 2019)。Web 技术和地理空间

Web 服务的发展使得用户可以轻松地在空间数据基础设施上发现、访问和处理地理空间数据（Zhao 等，2012）。例如，戈达德地球科学数据和信息中心开发的地理空间交互式在线可视化和分析基础设施（Berrick 等人，2009 年），以及欧洲航天局开发的网格按需处理系统（ESA，2012 年）。用户可以使用由数据服务、传感器 Web 服务和处理服务等地理空间 Web 服务组成的科学工作流程来定制数据产品。地理空间数据可以通过互联网以可互操作的方式访问，并且处理可以迁移到远程服务器，而不是在本地计算机上执行（Yue 等人，2010）。这称为面向服务的处理范式。近年来，分析就绪模式已成为大地理空间数据处理的革命性范式（Gorelick et al. 2017, CEOS 2021）。它需要将 EO 数据预处理为可供分析的形式，然后利用网络信息基础设施将数据提供给用户。分析就绪数据 (ARD) 意味着 EO 数据按照一组最低要求进行处理，从而以最少的额外用户工作量和互操作性实现即时分析（Lewis 等人，2018）。ARD 可以合并到地理空间数据立方体中，这使得大 EO 数据更易于访问并启用

图 1. EO 处理的范式转变。

第 1854 章

使用高性能计算（HPC）技术（例如并行计算或云计算）进行大规模分析。本研究提出了用于大地理空间数据分析的立方体基础设施。与现有的立方体方法相比，该基础设施强调多源地理空间数据的容纳，包括立方体中的栅格和矢量数据、云计算的立方体瓦片处理以及人工智能（AI）

支持机器学习的立方体计算。AI 支持的立方体计算是指使用人工智能来预测并行立方体处理任务的计算强度（CI），这有助于提高负载平衡性能。本文详细介绍了称为 GeoCube 的立方体基础设施的设计和实现。它涵盖了立方体中多源地理空间数据的摄取和管理、沿不同立方体维度的地理空间数据查询和访问以及大规模地理空间数据集的高性能立方体计算。这种地理空间数据立方体的开发有助于推进 EO 数据立方体方法，并与商业智能 (BI) 立方体保持联系。

本文的其余部分组织如下：第 2 节介绍背景和相关工作。所提出的方法在第 3 节中描述。GeoCube 的实施和评估将在第 4 节中详细介绍。第 5 节进行讨论，第 6 节总结研究。

2.背景及相关工作

2.1.数据立方体概念

“数据立方体”一词源自 BI 领域。由于数据立方体通常是指便于在线分析的多维数组，因此也称为在线分析处理（OLAP）立方体（Gray et al. 1997）。将 OLAP 立方体引入地理空间领域，通过添加空间维度和空间测度来容纳矢量数据中的空间实体，从而将 OLAP 提升为空间 OLAP（SOLAP）（Han 等，1998）。近年来，该术语已在 EO 领域中用于指代时间序列多维数组（表

1)。它已被纳入 Cyberinfrastructure 中，以创建 EO 数据立方体基础设施，从而促进 EO 数据管理、访问、分析、可视化和互操作性。表 1 列出了数据立方体的几种典型定义，涵盖了 OLAP、SOLAP、数组数据库 (Baumann 2017)、地球科学信息学 (Nativi et al. 2017) 和开放地理空间联盟 (OGC) (Voidrot 和 Percivall 2020) 社区的定义。在本文的其余部分中，前两者被称为 BI 数据立方体，而后三种被归类为 EO 数据立方体。

人们通常认为，EO 数据立方体与 BI 数据立方体并不相似，尽管立方体概念相似。EO 数据立方体总是密集填充，而 BI 数据立方体通常是稀疏的，这限制了 OLAP 方法在 EO 数据立方体中的使用 (Strobl 等人, 2017)。连接两个多维数据集的一个主要挑战是以高性能形式组织数据以实现高效多维数据集处理的方式。在传统的 BI 数据立方体中，由于数据集稀疏，通常选择关系数据库进行立方体管理。然而，EO 《国际地理信息科学杂志》 1855

数据立方体通常需要更高性能的解决方案。此外，传统的 SOLAP 可以容纳矢量数据，而 EO 数据立方体专注于栅格数据。可以将空间维度和空间度量扩展到 EO 数据立方体中，以实现多源数据集的立方体分析。因此，有必要研究桥接 EO 和 BI 数据立方体的方法，通过多源地理空间数据摄取和管理来增强立方体，并对密集数据 (EO 数据) 和稀疏数据 (矢量或表格数据) 之间的联合数据分析进行立方体处理。

因此，在本研究中，地理空间数据立方体被理解为一种时间序列多维数据模型，其中多源地理空间数据可以以高性能形式组织为空间对齐的 ARD。多源地理空间数据不仅限于遥感图像等 EO 数据，还可以是矢量、轨迹、点云或表格数据。地理空间数据立方体使大 EO 数据更容易访问，并支持使用 HPC 技术进行大规模分析。

2.2. BI 数据立方体

BI 数据立方体最初由 Gray 等人 (1997) 提出用于业务数据管理，它使用维度、度量、单元格和级别等概念以多维数组的形式表示业务数据。数据立方体由单元组成，可以根据其维度和度量来定义单元。尺寸

表 1. 数据立方体的几种定义。

参考定义 数据立方体：概括分组、交叉表和小计的关系聚合运算符 (Gray 等人, 1997) OLAP 立方体是多维数据数组。0 维数据立方体是一个点。一维数据立方体是一条带有点的线。二维数据立方体是一个交叉表、一个平面、两条线和一个点。3D 数据立方体是具有三个相交的 2D 交叉表的立方体。

选择性物化：空间数据立方体构建的有效方法 (Han et al. 1998) 空间数据立方体是空间和非空间数据的面向主题的、集成的、时变的和非易失性的集合，由空间和非空间维度和度量组成。

数据立方宣言 (Baumann 2017) 数据立方是一个巨大的多维数组，也称为“栅格数据”或“网格数据”；“大规模”意味着我们谈论的大小远远超出了服务器硬件的主内存资源。数据值全部具有相同的数据类型，位于由 d 维数据立方体的 d 轴定义的网格点处。

沿着这些轴的坐标允许明确地寻址数据值。 d 维网格的特点是每个内部网格点沿每个方向恰好有两个邻居；边界网格点只有一个。

支持大地球数据系统互操作性的基于视图的数据立方体模型 (Nativi 等人, 2017) 准备进行分析的空间对齐像素的时间序列多维 (空间、时间、数据类型) 堆栈。

OGC 地理空间覆盖数据立方体社区实践 (Voidrot 和 Percivall 2020) 多维 (‘ n -D’) 值数组。尽管它被称为“立方体”，但它可以是 1 维、2 维、3 维或更高维。维度可以是坐标或枚举，例如

类别。地理空间数据立方体是在特定网格系统覆盖的基础上建立的具有至少一维空间或时间定义的地理空间数据的数据立方体。

第 1856 章

表示分析轴，度量是由维度组合标识的数值变量。维度可以按层次结构组织为多个级别，每个级别对应于该维度的不同粒度 (Damiani 和 Spaccapietra 2008)。考虑营销销售示例，可以定义一组维度，例如位置、时间和产品类型。该度量可以通过销售额来定义。因此，可以使用位置、时间和产品类型维度来识别。其中，时间维度可以用日、月、年等不同级别来表示，这样销售额的值就可以沿着维度进行聚合 (Rivest et al. 2001)。

BI 数据立方体始终与 OLAP 方法一起使用。OLAP 可以在不同聚合级别存储数据集的不同多维数据集版本，从而提供复杂且快速的聚合过程来汇总数据 (Kasprzyk 和 Devillet 2021)。

OLAP 为用户定义了几种探索数据立方体的操作 (Chaudhuri 和 Dayal 1997)：/C15 修剪和切片，沿维度执行数据选择；/C15 roll up，沿着一个或多个维度向上移动以获得更多聚合数据；/C15 向下钻取，沿着一个或多个维度向下移动以获得更详细的数据；/C15 枢轴，它针对不同的视图重新定位数据立方体。

空间属性是地理空间数据的一个重要维度。直接使用 OLAP 维度作为空间维度并不能支持空间实体的聚合过程。因此，SOLAP 被提出，它定义了空间维度和空间测度的含义 (Han 等, 1998)。空间维度与一个几何实体相关联，该几何实体可能具有不同的空间粒度，例如国家、省份、城市。空间度量是空间实体的指针的集合 (Han 等人, 1998 年；Bimonte 等人, 2010 年)。因此，空间维度类似于空间索引，而空间度量类似于空间特征的集合。这样的模型使得执行空间聚合函数成为可能，例如交集和并集，通过这些函数可以从空间测量返回一组几何图形 (Silva 等人, 2008)。

OLAP 提供了多种在数据库中实现数据立方体的方法。最常用的方法是星形、雪花和事实星座模式（Chaudhuri 和 Dayal 1997）。在星型模式中，数据立方体被表示为星形，星形的中心是事实表（即立方体单元中的度量）表，星形周围的点由维度表组成（Kimball 和 Ross 2011）。尽管星型模式是数据库中数据立方体模型最简单的实现，但它不能显式支持维度层次结构。因此，开发了雪花模型来完善星型模型。在雪花模式中，维度层次结构可以通过规范化维度表来表示。事实星座模式更加灵活，因为它允许多个事实表共享数据库中的维度表（Chaudhuri 和 Dayal 1997）。以这种方式，它提供了《国际地理信息科学杂志》 1857

实现由共享多个公共维度的多源和异构地理空间数据组成的数据立方体的可能性。

2.3. EO 数据立方体

近年来，数据立方体受到了越来越多的关注，并在对地观测领域展现了从大对地观测数据中提取有用信息的巨大前景（Baumann et al. 2016、Giuliani et al. 2017、Sudmanns et al. 2019、Schramm et al. 2021）。

EO 数据立方体可以定义为可供分析的空间对齐像素的时间序列多维（空间、时间和数据类型）堆栈（Nativi 等人，2017）。虽然现有的 EO 数据立方体主要集中在图像上，但在本研究中，立方体的概念被扩展到涵盖其他地理空间数据源，例如矢量数据，从而提供多源地理空间数据立方体。

表 2 比较了三种典型的 EO 数据立方体和提议的数据立方体

地理立方体。EarthServer 数据立方体是使用 Rasdaman 阵列数据库系统创建的（Baumann 等人，1999）。它支持洲际规模的数据管理、临时提取和处理（Baumann 等人，2016 年、2018 年）。多维数据集可以使用 PostgreSQL 数据库或文件系统来存储数据，尽管 PostgreSQL 选项最近已被弃用。元数据使用 OGC 地理标记语言覆盖范围 (GMLCOV) 规范表示，存储在 PostgreSQL 或 SQLite 中。支持 R+树、常规计算索引等多种数据索引方式。EarthServer 数据立方体支持 Rasdaman 之上的 Petascope 提供的 Web 服务接口，包括 OGC Web 覆盖服务 (WCS) 和 Web 覆盖处理服务 (WCPS)。

表 2. 不同数据立方体的比较。

EarthServer 数据立方体 开放数据立方体 地球系统数据立方体 GeoCube 数据源 栅格数据 栅格数据 栅格数据 栅格数据/矢量数据 空间 OLAP 否 否 是 计算模式 HPC HPC HPC HPC/AI 支持的计算强度预测 数据组织 栅格切片 栅格切片 栅格切片 栅格切片/矢量切片 元数据 PostgreSQL/SQLite (GMLCOV 模型)

PostgreSQL (JSONB) 文件系统（配置文件） PostgreSQL（事实星座架构） 提供基于数组的接口是是是是数据索引 平铺索引 场景和平铺索引 平铺索引 平铺索引 数据摄取 强制 可选 强制 强制 用户交互 WCS/WCPS、rasql、C#p/Java/R/ JavaScript API WCS/WMS/WPS、Jupyter Notebook、Python API FTP/WCS、Jupyter 笔记本、Python/Julia/R API OGC API – 覆盖范围/流程、OGC 数据访问和处理 API、Jupyter Notebook、Scala/Python API 1858 F. GAO 等人。

这些服务请求可以转换为 Rasdaman 查询语言 (RaSQL) 并在 Rasdaman 数据库中执行 (Rasdaman 2021)。开放数据立方体 (ODC) 倡议是一个开源项目，由对地观测卫星委员会 (CEOS) 发起 (CEOS 2021, Gomes 等人 2021)。

2021)。ODC 的目标是降低技术壁垒，为国家或地方机构提供创建数据立方体的解决方案，这些数据立方体类似于澳大利亚地球科学数据立方体、哥伦比亚数据立方体和瑞士数据立方体 (Lewis et al. 2017, CEOS 2021)。ODC 可以管理大量卫星数据，并利用 HPC 技术处理全国范围甚至大陆范围的卫星数据。它允许以原始格式存储数据或以高性能切片格式摄取数据。

前者采用传统的基于场景的索引，而后者采用基于瓦片的索引。尽管最近为 ODC 推荐了前一种选项，但可以在两种组织形式之上强制执行相同的 API。Dask 并行计算引擎可在 ODC 中用于并行地球科学、卫星图像和时间序列分析 (Dask 2021)。与 ODC 中的 Dask 不同，GeoCube 选择 Apache Spark (Zaharia et al. 2010)，因为它在开源云计算社区中拥有更广泛的用户基础，拥有更多的编程语言和涵盖 Hadoop、HBase 和 Geotrellis 的全面软件生态系统。在 ODC 中，平铺格式的 EO 数据使用网络通用数据格式 (NetCDF) 进行存储。

元数据使用 JSONB 格式进行编码，并在 PostgreSQL 数据库中进行管理 (Lewis 等人, 2017 年)。利用五个关系表来管理多维数据集数据。此外，ODC 还提供 Web 服务接口，包括 OGC WCS、Web 地图服务 (WMS) 和 Web 处理服务 (WPS) (Voidrot 和 Percivall 2020)。

地球系统数据立方体 (ESDC) 的目标是同时探索各种 EO 栅格数据流以实现联合分析。多个数据流被集成到单个高维数据立方体中。该基础设施以不同的空间分辨率和分块提供相同的数据立方体，以加速不同应用程序的数据访问 (Mahecha 等人, 2020)。多维数据集数据使用 Zarr 格式 (Zarr 2021) 进行编码，这是一种针对云存储进行优化的格式。ESDC 使用文件系统目录来组织数据，每个立方体实例都有一个用于描述空间和时间分辨率的配置文件。ESDC 支持通过文件传输协议 (FTP) 检索和下载数据。此外，还支持 OGC WCS 和 Jupyter Notebook 进行数据访问和分析 (ESDC 2021)。

2.4.工作贡献

这项研究提出了一种用于大地理空间数据分析的新立方体基础设施。该方法与现有的立方体方法在以下方面有所不同：(1) 基础设施支持多源地理空间数据的容纳，包括立方体中的栅格和矢量数据。多源数据在 NoSQL 数据库中被分割成瓦片形式，为 HPC 做好准备，从而使用户能够利用高性能瓦片形式进行高效的多源数据分析。(2) 基础设施支持使用基于云的立方体对象对立立方体瓦片进行大规模联合分析。

兼容多种数据源，可帮助解决《国际地理信息科学杂志》1859 的问题

多源异构地理空间数据的联合分析。SOLAP 和 EO 数据立方体在云计算环境中协同工作。云计算是指按需使用位于联网计算机上的存储和计算资源。现有的云计算技术（例如 Apache Spark）已广泛用于大数据处理。Apache Spark 是一个高性能云计算引擎，专为数据密集型应用程序开发。它包含一个称为弹性分布式数据集 (RDD) 的数据模型，它是跨一组机器进行分区以进行分布式计算的数据集合 (Zaharia 等人, 2010)。利用云计算和该数据模型可以显著提高立方体基础设施的处理能力。(3) 基础设施利用人工智能改善并行地理处理的负载平衡。尽管云计算为基础设施提供了并行地理处理能力，但地理空间数据是异构的且空间分布不规则，由于不同切片的计算强度不同，常常导致负载不平衡。AI 机器学习技术在 CI 评估方面已显示出潜力 (Yue 等人, 2020)，可以将其纳入分布式瓦片处理中以改善负载平衡。

3 材料与方法

本节介绍构建面向大规模地理空间分析的多源时空数据立方体的方法。该方法包括立方体维度的形式化以适应多源数据（第 3.1 节）、使用云计算进行立方体平铺处理（第 3.2 节）以及使用人工智能增强立方体计算（第 3.3 节）。

提出了一种具有以下特征的新地理空间数据立方体。首先，立方体中可以容纳多源地理空间数据，包括栅格和矢量数据。时间、空间、产品、频带四个维度被形式化。

多源数据在空间上排列并以时间序列形式堆叠。因此，它被命名为多源时空数据立方体。立方体是使用 OLAP 事实星座模式开发的，因此可以在立方体上进行空间合并、地图代数和时间序列分析等 OLAP 操作（第 3.1 节）。

其次，使用云计算来处理立方体瓦片。提出了立方体瓦片的分布式立方体对象以促进分布式计算（第 3.2 节）。第三，应用人工智能技术增强立方体计算的负载平衡。可以使用人工智能机器学习从数据科学的角度捕获地理空间数据的异构性，从而优化并行计算性能（第 3.3 节）。

3.1.立方体维度形式化

多维数据集维度对于多维数据集数据模型的开发非常重要。地理空间数据可以用多个维度表示，例如空间、时间和专题属性。该模型指定了几个基本维度来容纳栅格、矢量和表格数据，如图 2 所示。

第 1860 章

3.1.1.产品尺寸

该维度使用产品名称（例如 Landsat_8_ARD 或 OSM_Water）、类型（例如栅格、矢量或表格）、进程和仪器名称指定地理空间数据立方体的专题轴。产品和仪器名称分别链接到 Product&Band 和 Instrument 表，这些表在使用栅格数据时用作补充表。例如，产品维度可以通过记录仪器和波段信息来描述光学和 SAR 图像产品。当考虑诸如 OpenStreetMap (OSM) 等矢量数据产品时，补充表不是必需的。流程是产品已支持且可以执行的功能。可以使用产品名称沿产品维度进行数据查询或子集化。

3.1.2.空间维度

该维度使用网格代码、网格类型、城市名称和省份名称指定地理空间数据立方体的空间轴。该立方体使用空间网格进行平铺，以高性能形式实现数据准备。栅格数据的切片涉及将数据划分为物理切片，而矢量数据的切片涉及将数据索引为逻辑切片而不是物理划分，这有助于维护

图 2. 多维数据集数据模型。

《国际地理信息科学杂志》1861

向量特征的完整性。空间网格的分辨率是可定制的，例如 1 /C2 1 网格瓦片（网格大小），由 4000 /C2 4000 像素（像素大小）组成。网格类型表用于重新编码网格的布局，包括网格和像素大小，以及坐标参考系统（CRS）。CRS 可以是世界大地测量系统 1984 (WGS 84) 或投影坐标参考系统，例如通用横轴墨卡托，具体取决于用户规范。网格代码被分配给每个瓦片以启用网格瓦片的索引。该代码遵循基于 Z 阶曲线的编码，以便将连续的瓦片分配给同一节点，从而由于降低了通信成本而提高了查询和计算性能。当考虑边界框查询时，将首先确定与边界框相交的网格，然后可以在数据库中找到使用 Z 顺序曲线编码的网格。由网格代码标识的瓦片数据通常位于同一节点中。城市和省份名称可用于支持某些 OLAP 聚合操作。

3.1.3. 时间维度

该维度使用现象时间和结果时间指定地理空间数据的时间轴。现象时间是捕获观测的时间，例如卫星图像的采集时间以及矢量和表格数据的更新时间，而结果时间是所有处理步骤完成后结果可用的时间。可以使用现象时间来执行沿时间维度的数据查询或子集化。

3.1.4. 带尺寸

该维度根据波段名称、SAR 影像保留的偏振模式以及产品级波段描述了栅格产品的波段属性。产品级频段是从原始频段中提取的信息。例如，归一化水份指数 (NDWI) 波段是从原始绿色和近红外波段生成的产品级波段。

该模型允许根据用户指定创建一个或多个立方体。每个立方体都有统一的空间分辨率和 CRS。可以为多个数据集创建多个多维数据集，这有助于保留原始信息。可以跨不同的立方体执行查询，然后将不同的立方体数据重新采样并重新投影为统一的空间分辨率和数据。此外，可以创建多源数据集在空间上对齐的立方体。此选项需要将数据集重新采样并重新投影为统一的空间分辨率和数据。图 2 中的多维数据集管理部分展示了多维数据集元数据架构。

图 2 中的维度形式化部分遵循事实星座模式。栅格、矢量和表格切片事实表共享产品、空间和时间维度。表格数据具有在空间对齐的立方体中摄取空间维度的最低要求。这可以通过表数据中的地名属性来实现，随后可以使用现有的地理编码服务将其转换为空间维度。多维数据集数据模型中使用两种类型的度量：数据度量和计算度量。数据测量参考 1862 F. GAO 等人。

瓦片，它使用物理栅格瓦片的瓦片 ID、与逻辑矢量瓦片空间相交的要素的矢量 ID，或与逻辑表格瓦片空间相交的表格记录的表格 ID。计算度量由基于瓦片的计算强度评估的值组成。以下部分描述如何利用多维数据集数据模型。

多维数据集数据模型中维度的形式化有助于支持地理空间数据的 OLAP 操作，例如修剪、切片和汇总。修剪和切片是用于立方体中地理空间数据的最简单操作（Baumann 2017、Voidrot 和 Percivall 2020）。Trim 沿不同维度选择多个值，而 slice 可以通过沿维度选择单个值来生成维度减小的子立方体。图 3(a) 描述了沿着时间和空间维度的修剪操作，它可以在给定的空间范围和时间内返回一堆瓦片。沿频带和时间维度的切片操作如图所示

图 3(b)。已经提出了几种用于查询立方体数据的接口，例如

`getData($QueryParams)`，用于访问栅格/矢量/表格数据。可以使用多维数据集标识符和一组维度信息来启动 QueryParams 类。Roll up 是一种比较复杂的 OLAP 操作，它是沿着不同维度层次的数据聚合过程，例如空间维度上的网格/城市/省，时间维度上的日/月/年，带状维度上的原始/产品

级带，以及产品维度上的不同级别产品。OLAP 运算的结果可以预先计算并保存，以创建不同维度级别的新立方体，从而使用户更快地响应。以洪水灾害为例，通过洪水图像（一种栅格数据）和村庄（一种矢量数据）之间的交叉分析来识别被淹没的村庄（图 3（c））。聚合沿着产品维度发生，被淹没的村庄是更高级别的产品，这可以帮助创建具有更高级别产品维度的新立方体。聚合涉及 Join 和 Intersection 操作。Join 操作用于基于时空的多源数据进行连接

图 3. 多维数据集 OLAP 操作。

《国际地理信息科学杂志》1863

标识符之后，就可以在同一时空空间内对栅格数据和矢量数据进行交集运算。该示例可能涉及更多的汇总聚合，例如沿空间维度的瓦片马赛克的空间合并函数以及沿空间维度的总受影响人口计算的求和函数。

3.2.使用云计算处理立方体瓦片

了解如何以高性能形式组织数据以实现高效的多维数据集处理非常重要。本节介绍如何利用云计算为瓦片设计分布式立方体对象，从而促进高性能分布式计算。

3.2.1.瓷砖的分布式立方体对象。瓦片的分布式立方体对象是

通过将瓦片与云计算中的分布式对象桥接而设计。栅格数据被分割成具有均匀投影和立方体空间维度分辨率的瓦片。矢量数据被分割成逻辑块以维持其拓扑。逻辑平铺意味着如果矢量与网格相交，则矢量数据并未物理分段而是附加到网格。这有助于保留矢量数据的几何信息并促进其并行空间分析。数据瓦片按特定时间间隔组织，例如时间维度中的日、周、月和年，而瓦片是根据产品/带维度中的产品/带类型的分类来组织的。因此，栅格切片可以通过乘积/频带、空间和时间维度来描述，而矢量切片可以使用乘积、空间和时间维度来描述。

典型的软件（例如 Apache Spark）包含云计算中 HPC 的分布式对象。核心对象模型是 Spark RDD 类。因此，可以将 Spark RDD 的分布式计算能力与立方体中的瓦片结合起来，从而实现 HPC 中的数据并行性。随后，一组分布式立方体对象被用于立方体块。图 4 显示了对应的层次结构和转换。CubeRDD[T] 是包含键值对集合的顶级类，它继承自抽象 RDD 类。CubeRDD[T] 的键类型是固定的（即 SpaceTimeProductKey 类），涉及产品、空间和时间维度，这是多源地理空间数据（包括栅格和矢量数据）的常见维度。值类型 T 是地理空间数据类型（例如栅格和矢量切片）。它旨在支持多源数据，从而使立方体对象可扩展，从而容纳其他数据类型，例如轨迹数据。CubeRDD[T] 还提供网格布局、空间和时间范围以及 CRS 信息。

针对栅格数据的 RasterRDD 和针对矢量数据的 FeatureRDD 是基于 CubeRDD[T]设计的。RasterRDD 可以从 CubeRDD[RasterTile] 转换而来，其中 RasterTile 类包含波段信息和像素数据数组。因此，RasterRDD 除了产品、空间和时间维度之外还可以包含带维度。FeatureRDD 可以从 CubeRDD[FeatureCollection] 转换而来，1864 F. GAO 等人。

其中 FeatureCollection 类包含一组几何图形及其相应的属性。通过仅保留几何信息，可以将 FeatureRDD 转换为 SpatialRDD。随后，可以从 SpatialRDD 创建 PointRDD、PolylineRDD 和 PolygonRDD，因为几何图形可以是点、折线或多边形。

CubeRDD 设计使得沿不同维度执行地理处理变得更加容易。例如，RasterRDD 可以沿时间维度分组以实现分布式时间序列分析，或沿频带维度分组以执行分布式频带代数运算，例如归一化差异植被指数。

一个 FeatureRDD 可以沿着产品维度进行分组，以支持两个产品之间的分布式空间交集。RasterRDD 和 FeatureRDD 可以连接在一起，以定位共享公共维度的栅格和矢量切片，从而实现多源地理空间数据的分布式联合分析。

3.2.2.立方体查询和处理

多维数据集查询和处理操作如图 5 所示。首先，多维数据集接收并解析多维查询参数，然后从维度和事实表中检索瓦片 ID。这些区块 ID 被分区并分配给每个计算单元，以实现并行数据访问。立方体处理包括批处理、云计算和多线程计算。云计算和多线程计算的使用形成了混合并行，这是指分布式并行和共享内存并行的混合（LLNL 2021）。

批处理解决了大量瓦片无法同时加载到内存的问题，它用于将瓦片分成多个批次。每个批次都可以作为一个整体加载到内存中。因此，批处理使得能够用有限的存储器处理大量的瓦片。每个批次都作为分布式多维数据集对象 (CubeRDD) 进行访问。此外，还创建了一个多线程池来处理每个大瓦片。瓷砖的尺寸可能非常大，例如高

图 4. 分布式多维数据集对象。

《国际地理信息科学杂志》1865

分辨率图像或包含大量多边形的网格，导致数据处理的时间成本很高。因此，立方体处理需要混合并行处理。每个子线程只处理多线程池中瓦片的一部分，处理结果集中在主线程中。这样，数据处理就涉及到计算节点之间的多个进程和一个节点内的多个线程，从而形成混合并行。

例如，时间段 2017.01.01 至 2020.12.31 可分为 2017.01.01 至 2018.12.31 和 2019.01.01 至 2020.12.31，而空间范围(110 /C14 E, 25 /C14 N, 120 /C14 E, 35 /C14 N)可分为 (110 /C14 E、25

/C14 N、115 /C14 E、35 /C14 N) 和 (115 /C14 E、25/C14 N、120 /C14 E、35 /C14 N)。随后，根据上述划分分组的批处理瓦片被访问并作为分布式立方体对象返回，并在 Spark 云环境中进行处理。每个进程中可以创建包含 8 个线程的多线程池，每个线程将一个 tile 分为 8 个子 tile。线程的处理结果被聚集，最后，批次的结果沿维度进行合并。

3.3.使用 AI 进行立方体计算优化

数据被组织为瓦片，加载到多维数据集中的分布式计算节点中。不同的切片在地理处理算法和异构空间特征分布方面具有不同的 CI。负载均衡是立方体计算中的一个挑战，通常使用两种方法来解决这个问题：静态调度和动态调度。动态调度通过监控集群的状态并将任务分配给空闲的计算单元来缓解负载不平衡。然而，当任务数量极少或极多时，该策略的优势就受到限制。任务太少可能难以实现负载均衡，而任务太多往往导致通信成本较高。静态调度可以预先将数据划分并分组到计算强度均衡的分区中。CI 评估的准确性是该策略成功的关键。

GeoCube 使用 AI 机器学习方法评估瓷砖的 CI。这项工作是之前关于在并行地理处理中预测 CI 的机器学习方法的研究的延续 (Yue 等人, 2020)，该方法扩展到了切片 CI 的评估。图 6 显示了如何在多维数据集基础设施中使用该方法来预测多维数据集瓦片的 CI。地理空间 CI 评估模型

图 5. 使用批处理计算、云计算和多线程计算进行多维数据集处理。

第 1866 章

分析是使用人工智能机器学习特征选择和回归训练生成的。采用特征选择来评估一组可能影响强度的候选计算特征的重要性。这些特征可以根据经验知识来准备并在训练阶段进行评估。使用模型训练和验证来评估机器学习回归算法，以确定 CI 预测的最佳模型。可以在计算之前使用模型评估瓦片的 CI，并将其保存在多维数据集基础设施中。当执行特定的立方体分析时，计算成本可以直接从存档的 CI 中得出，而不是动态评估，从而丰富 ARD 的内容并节省分析阶段的时间。

CI 与立方体的丰富遵循与 n 元地理处理函数相对应的 n 元模型。在 1 元情况下，每个切片都有一个 CI 值，对应于具有一个输入的 1 元地理处理函数，例如三角测量和 NDWI，可以形式化如下：

$CI_k = \text{tfDimensions}_{\text{sg}} \cdot \frac{1}{4} \cdot f_k \cdot X_{\text{tDimensions}_{\text{fg}}} / C0/C1, (1)$ 其中 $\text{tfDimensions}_{\text{sg}}$ 是由特定维度标识的立方体切片， $CI_k / C3_{\text{d}}$ 是地理处理 k 中切片的 CI 值， $X_{\text{d}/C3_{\text{d}}}$ 返回切片的计算特征列表， f_k 是用于地理处理 k 的预训练机器学习模型， f_k 使用一组计算特征作为输入并返回 CI 值。

在 2 元地理处理情况下，函数具有两个输入（例如两层交集），每个切片都有一个 CI 值，该值与多维数据集中另一个产品的切片相关联。它可以形式化如下：

图 6. 使用支持 AI 的 CI 预测方法进行立方体计算。

《国际地理信息科学杂志》1867

$CI_{k,i} = f(\text{dimensions}_{g\delta P} \setminus k \times \text{dimensions}_{fg}, \text{dimensions}_{g\delta P} / C0 / C1)$, (2) 其中 $CI_{k,i} / C3\delta P$ 是与地理处理 k 中目标产品 i 的切片关联的切片的 CI 值， dimensions_{fg} 是目标产品 i 的切片， $X \delta / C3P$ 返回两个切片的计算特征列表。

在 n 元地理处理情况下，每个切片都有一个 CI 值，该 CI 值与多维数据集中其他 $n-1$ 个产品的切片相关联，可以形式化如下： $CI_{k,L} = f(\text{dimensions}_{g\delta P} \setminus k \times t \text{ 维度 } fg, t1 \text{ 维度 } fg, t2 \text{ 维度 } fg, \dots, t_{n/C0-1} \text{ 维度 } fg) / C0 / C1, l1, l2, \dots, l_{n/C0-1} \text{ 升}$, (3)

其中 $CI_{k,L} / C3P$ 是与地理处理 k 中其他 $n-1$ 个产品 L 的切片关联的切片的 CI 值， $tL \text{ 维度 } fg$ 是关联的切片列表， $X \delta / C3P$ 返回 n 个切片的计算特征列表。

上述模型为立方体中 CI 值的设定提供了理论依据。在实际应用中，许多地理处理函数都是一元或二元的情况。JSON 数据结构可用于记录 CI 值。更具体地说，CI 值使用 JSON 文件保存在第 3.1 节的事实表中，其示例如图 6 所示。一种是针对单个产品的地理处理，例如空间缓冲，另一种是针对两个产品之间的地理处理，例如空间交集。在前者中，每个切片对于特定的一元地理处理函数都有一个 CI 值。在后者中，每个瓦片可以具有与特定二元地理处理函数的立方体中的目标产品之一相关联的 CI 值，前提是目标产品在语义上可接受作为二元地理处理函数的第二输入。例如，瓦片可以具有与二元函数中的产品瓦片(#1、#2、...)相关的 CI 值。

可以根据 AI 预测的 CI 将瓦片分配给计算单元进行平衡处理。CI 值是在访问立方体瓦片时获得的，可以根据 CI 值对立方体瓦片进行分组并分配给计算单元。随后，可以在立方体计算中实现有效的负载平衡。

四、实施与评估

4.1. 实施

立方体基础设施作为 GeoCube 软件实现。图 7 展示了 GeoCube 实施架构。前端为用户提供了三种类型的界面：Jupyter Notebook、OGC 地理空间 Web 服务和 Web UI。后端包括四个模块：数据源模块、数据存储模块、数据访问模块和计算引擎模块。数据源模块管理多源地理空间数据，

可以是 Landsat、高分、Sentinel 等 EO 数据，也可以是 OSM 等矢量数据，也可以是高水平的遥感产品。

可以下载外部来源的数据并将其预处理为分析就绪级别。元数据数据库可用于管理 ARD 和为其建立索引。用户可以根据元数据检索 ARD，然后将数据提取到多维数据集中。在摄取期间，数据被重新投影、重新采样，并根据立方体配置划分为瓦片。立方体数据存储模块管理 1868 F. GAO ET AL。

通过利用关系数据库和 NoSQL 数据库来管理切片：维度和事实表使用关系数据库进行管理，而栅格和矢量数据表使用分布式 NoSQL 数据库进行管理。栅格数据表记录瓦片 ID 和瓦片数据字节。矢量数据表记录了矢量数据 ID、WKT 编码的几何信息以及 JSON 编码的属性。数据访问模块支持地理空间数据沿空间、时间、产品和波段维度的多维查询。

计算引擎模块将云计算与分布式立方体对象和基于 AI 的 CI 预测方法相结合，提高地图代数、时序分析、空间分析、多源联合分析等立方体数据处理的计算性能。

在 GeoCube 中，事实星座模式是使用 PostgreSQL 9.3.24 (Momjian 2001) 实现的，栅格和矢量切片保存在 HBase 1.4.13 (George 2011) 中，该 HBase 1.4.13 (George 2011) 构建在 Hadoop 2.7.4 (White 2012) 上。Spark 2.4.3 (Zaharia 等人，2010)

Geotrellis 3.0.0 (Geotrellis 2021) 用于开发分布式内存立方体对象，用于并行数据摄取、数据访问和数据处理。机器学习算法使用 Python 3.7 和 Scikitlearn 0.20.3 实现 (Pedregosa 等人，2011)。OGC Web 服务使用 Springboot 2.3.1 (Spring Boot 2021) 实现。标准服务接口允许用户以可互操作的方式访问多维数据集数据并执行多维数据集功能。对于

图 7. GeoCube 的实现架构。

《国际地理信息科学杂志》1869

例如，用户可以使用 OGC Coverages API 访问标准覆盖数据而不是立方体瓦片。使用 Jupyter Notebook (Jupyter 2021) 创建基于 Web 的交互式开发环境，并使用 Cesium 1.71 进行数据可视化 (Cesium 2021)。

4.2.概念证明

4.2.1.多维数据集 OLAP 操作

GeoCube 使用户能够在立方体数据的各个级别之间导航，范围从最详细到最聚合。例如，“年”在时间维度上比“月”和“日”更聚合。本节提供了如何在两个不同级别探索多维数据集数据的示例。

图 8(a) 展示了使用最详细的空间、时间和波段维度进行的 NDWI 分析。该级别要求用户提供经度/纬度 (WGS 84) 形式的空间范围、特定于“日”的时间范围以及原始传感器波段。空间范围被转换为一系列覆盖网格的 Z 阶曲线代码。正如立方体数据模型中设计的那样，网格是空间维度最详细的层次。类似地，白天和原始传感器波段分别是时间维度和波段维度的最详细级别。

图 8(b) 描述了更聚合水平的 NDWI 分析。用户可以提供

空间维度中的城市或省名称。一个城市或省份覆盖了多个网格，这些网格比网格更聚合。使用“武汉”城市覆盖的数据来导出图 8(b) 中的 NDWI 产品。时间维度支持比日聚合的查询参数，例如月、年。可以聚合同月或同年的 Cube 数据。

2017 年的数据用于推导图 8(b) 中的 NDWI 产品。产品级频段在频段维度上比原始频段更加聚合。例如，NDWI 波段比原始波段更加聚合，包括绿色和近红外波段。可以聚合两个波段以执行地图代数运算以计算 NDWI 波段。

可以预先计算并保存从聚合级分析得出的结果，以创建新的多维数据集，该新多维数据集由更多聚合级维度定义。例如，空间维度包括武汉等城市，而不是网格；时间维度包括年份，例如 2017 年，而不是天；波段维度包括产品级波段，例如 NDWI，而不是原始波段。预计算方法可以通过查询新的多维数据集而不是即时执行计算来更快地响应用户。

4.2.2. 大规模时间序列地理处理

多维数据集的一个显着优点是它支持大规模时间序列地理处理。我们以水存在频率分析的计算为例。它是一种时间序列分析，可检测一段时间内是否存在水，并将结果总结为每个像素检测到水的次数。分析涉及空间合并（即瓦片马赛克）和时间聚合（即像素值平均）（Mueller 等人，2016）。

第 1870 章

图 9 显示了水存在频率分析的结果，即

源自 2013 年至 2018 年覆盖湖北省的 Landsat 8 影像。结果中的高值表明该区域大部分时间被检测为水体，反之亦然。该分析考虑了 GeoCube 在批处理、云计算和多线程计算方面的优势。将瓦片沿空间维度分成批次，以确保瓦片的完整时间序列堆栈。分析中使用了大约 1 TB 的数据。将数据加载到内存中大约需要 1.4 小时，完成处理需要 1 小时。第 4.3.2 节提供了更全面的性能分析。

4.2.3.多源数据立方体分析

GeoCube 与现有立方体方法的不同之处在于它可以支持立方体中的多源数据分析。本节以洪涝灾害为例，演示如何在 GeoCube 中利用多源数据进行快速响应。推测此次灾难是由袭击中国南部的热带气旋造成的

图 8. GeoCube 中的 OLAP 操作。

《国际地理信息科学杂志》 1871

和越南北部。飓风伴随着暴雨，导致城市出现洪涝灾害。数千人被疏散，许多设施受到影响。本案例涉及栅格数据（如遥感图像）、矢量数据（如

设施特征）和表格数据（例如人口）。GeoCube 可以通过对这些多源数据的分析来帮助获得洪水淹没数据产品、受影响的设施和受影响的人群。

在案例实现中，从高分一号影像中提取灾前和灾后的水体，然后通过灾前和灾后数据相减即可生成洪水淹没产品。随后，可以使用洪水淹没产品来提取受影响的设施，例如道路、桥梁、村庄和学校。图 10 描绘了洪水淹没产物（红色区域）和受影响的桥梁（红色图标）。此外，人口数据可用于通过将村庄名称与矢量数据进行匹配来得出受影响的人口。图 11 展示了使用 Jupyter Notebook 提取洪涝灾害期间受影响村庄和受影响人口的过程。该过程包括导入 GeoCube 内核、多维度查询、评估受影响的桥梁和受影响的人群并显示结果。内核包含 GeoCube 的核心 API，例如 `getData()`。所有这些数据产品和统计结果都可以快速为灾害应对决策提供信息支持。

4.3.绩效评估

本节提供了演示 GeoCube 性能的实验。

图 9 使用涵盖湖北省的 Landsat-8 数据进行水存在频率分析的结果

第 1872 章 2013 年至 2018 年

4.3.1.数据与环境

实验中，GeoCube 中的栅格数据包括分辨率为 30 m 的 Landsat-8 操作陆地成像仪传感器、分辨率为 2/8 m 的高分 1 号全色和多光谱扫描仪以及分辨率为 16 m 的宽视场传感器的数据。GeoCube 中的矢量数据是从 OSM 获取的。

GeoCube 部署在三台物理服务器上。两台是 Inspure NF5280M4 服务器，每台均配备 Intel(R) Xeon(R) CPU E5-2690 v4 @ 2.60 GHz、CentOS Linux 版本 7.3.1611 操作系统、28 个 CPU 内核和 128 GB RAM。另一个是 Inspire

图 10. 洪水淹没产物（红色区域）和受影响的桥梁（红色图标）

洪水灾害。

图 11 利用数据提取洪涝灾害中受影响村庄和受影响人口的过程

Jupyter 笔记本。《国际地理信息科学杂志》1873

NF5270M3 服务器，配备 Intel(R) Xeon(R) CPU E5-2692 v2 @ 2.20 GHz、Ubuntu 14.04.1 操作系统、24 个 CPU 内核和 94 GB RAM。这些服务器连接到具有 PB 级存储空间的高性能存储阵列。具体来说，包括 84 个存储磁盘，每个存储磁盘的数据存储量为 16TB。

4.3.2. 查询和处理性能

本实验再次以水体存在频率分析为例，比较 ODC 和 GeoCube 的性能，以展示 GeoCube 的查询和处理能力。ODC 和 GeoCube 部署在同一环境中。使用 ODC 1.8.3，图像数据被摄取为瓦片并保存在文件系统中。Xarray 0.18.0 和 Dask 2021.3.0 库用于分布式计算。

图 12 展示了 ODC 和 GeoCube 的数据查询性能，其中

涉及瓦片 ID 检索和瓦片数据加载。可以看出，当数据量较小时，ODC 表现出比 GeoCube 更好的性能。但随着数据量的增加，GeoCube 的时间查询效率与 ODC 几乎相同。造成这种现象的原因是 GeoCube 中数据保存在分布式环境中。与 ODC 中数据集中保存在本地文件系统相比，GeoCube 在查询过程中会发生更多的网络通信，因为查询的数据如果没有保存在当前节点中，则必须从其他节点获取。

分布式存储方式对查询效率有一定的负面影响，但由于数据已经驻留在分布式节点中，因此可以显著提高计算效率。图 13 显示了 ODC 和 GeoCube 的处理性能。可以看出，无论数据量如何，GeoCube 的性能都优于 ODC。随着数据量的增加，GeoCube 比 ODC 节省了更多时间。造成这种现象的原因有两个：一是数据提前驻留在分布式节点中，从而减少了处理过程中的通信成本，二是提出的混合并行

图 12. 数据查询效率：GeoCube 与 Open Data Cube。

第 1874 章

计算方式，包括云计算中的多进程和多线程，显著提高了处理效率。

4.3.3. 负载均衡性能

以矢量数据的空间交集为例，演示 GeoCube 的负载均衡性能。GeoCube 中原始的没有 AI 增强的并行空间相交方法是一种经典方法，称为基于分区的空间合并连接（Patel 和 DeWitt 1996）。基于规则网格对数据进行分解，忽略了数据的异构性，从而导致严重的负载不平衡。

本节对 GeoCube 中原始方法和支持 AI 的 CI 预测方法的负载平衡性能进行了比较。矢量数据是从涵盖中国和印度的 OSM 收集的。实施了三个测试：第一个测试的数据集包含两个图层，分别为 1.69 和 49 万个多边形；第二个测试的数据集包含两个图层，分别为 2.50 和 82 万个多边形；第三个测试的数据集包含两个图层，分别为 3.00 和 87 万个多边形。在 AI 方法中，每个矢量切片的 CI 是使用 CI 预测模型预先计算的，并保存在 JSON 文件中，而在原始方法中 CI 被忽略。

图 14 显示了基于以下模型的不同 CI 预测模型的准确性：

特征选择和机器学习算法的结合。训练样本包含大约 1200 条记录，涵盖数据集的各个领域。在四种机器学习算法（即分类和回归树（CART）、随机森林（RF）、梯度提升回归（GBR）和支持向量回归（SVR））上，将四种特征选择算法（即 Pearson、递归特征消除（RFE）、平均杂质减少（MDI）和平均准确度减少（MDA））与所有特征（AF）一起进行测试（Yue 等人，2020）。R2 和平均绝对误差（MAE）这两个指标用于评估 10 倍交叉验证下的模型准确性。结果表明，使用 MDI 和 RF 组合的模型表现最好。该模型的 R2 和 MAE 分别为 0.78 和 456 ms。

图 15 展示了使用原始方法的不同阶段的时间成本

以及基于人工智能的 CI 预测方法。随着多边形数量的增加，

图 13. 数据处理效率：GeoCube 与 Open Data Cube。

《国际地理信息科学杂志》1875

使用两种方法时，数据查询阶段的时间成本几乎相等。然而，与原始方法相比，人工智能方法在处理阶段节省了更多时间。两种方法在三个数据集上的负载均衡性能如图 16 所示，它表明了每个执行器的时间成本。结果表明，AI 方法可以实现比原始方法更好的负载均衡性能。

5. 讨论

EO 和 BI 数据立方体都在大数据分析中得到了提倡，两者的协调对于支持 OLAP 操作非常重要。显著的

图 14. 特征选择和机器学习组合的不同模型的准确性

荷兰国际集团的算法：（a）R2 和（b）MAE。

图 15. 原始方法和 AI 方法之间的计算效率比较。

图 16. 原始方法和 AI 方法之间的负载平衡性能比较。

第 1876 章

EO 和 BI 数据立方体之间的区别在于 EO 数据立方体中的像素非常密集，而 BI 数据立方体中的元素总是稀疏的，这可能会限制 BI OLAP 方法在 EO 数据立方体中的使用。尽管两个立方体都可以定义维度和事实/单元，但一个关键挑战是以高性能形式管理密集的像素。高性能形式应该能够处理 EO 图像，并通过考虑多源地理空间数据的空间异质性和不同的数据结构来容纳它们。为了解决这些问题，本研究提出了一种增强立方体，具有多源地理空间数据摄取和管理以及云计算环境中的多源数据处理。这样的立方体可以继承 EO 数据立方体的大规模处理能力和 BI 数据立方体的数据管理能力。

立方体建模中为栅格和矢量数据定制了多个维度。然而，该模型并不限于栅格和矢量数据，它可以通过合并事实表和维度表来扩展以容纳更多数据源，例如轨迹数据。此功能借鉴自 BI 数据立方体。此外，这种方法支持对多维数据集数据进行 OLAP/SOLAP 操作，这些操作可以即时执行或使用预计算模式。后者提前计算几种常用的产品，以便可以交换存储以快速响应用户（Han 等人，1998 年，Koperski 等人，1998 年）。

多源地理空间数据的集成是在多源数据的单元粒度和维度共享形式化的前提下进行的。与现有的 EO 立方体相反，该方法通过添加空间度量在传统 BI 立方体中引入了 SOLAP 的思想。因此，该单元不是现有 EO 立方体的像素，而可以分别是栅格和矢量方面的一组像素和一组空间实体。此外，假设栅格/矢量/表格数据在空间对齐的立方体中可以具有相同的空间维度。

尽管此要求对于栅格和矢量数据来说已经足够，但对于表格数据来说，情况并不常见。在本研究进行的实验中，我们假设人口表格数据具有地名，可以对其进行地理编码并转换为空间维度。如果不是这种情况，则可以为表格数据创建 BI 立方体，并根据矢量/表格数据中的公共属性设置公共维度。因此，集成仍然可以基于公共维度而不是空间维度中的关节连接来发生。

数据立方体需要将外部数据重新组织成高性能的形式。这涉及到数据摄取期间的数据重复，这会增加开销。通常，开销包括存储开销以及空间对齐的潜在重采样和重投影开销。因此，探索复制的优化（例如压缩形式、分布式文件或 NoSQL 解决方案）将很有价值。并行数据摄取也是可能的，例如在云环境中，其基本原理与 OLAP 相同，即以存储换取快速响应。

云计算已广泛应用于地理空间基础设施。可以显着提高 Cube 的数据存储和处理能力。尽管云可能会导致隐私和可访问性等其他问题，但立方体供应商可以选择使用开放解决方案在自己的硬件上部署私有云，从而《国际地理信息科学杂志》1877

在私有环境中维护多维数据集数据的可访问性。此外，多维数据集和外部数据的耦合是灵活的：外部数据供应商可以部署多维数据集系统来提供多维数据集访问，也可以从外部数据供应商下载数据并摄取到本地多维数据集中。虽然 GeoCube 目前使用本地计算集群部署在私有云环境中，但它也可以用于公共云环境。所提出的基于 Spark 中间件的分布式多维数据集对象可以部署在公共基础设施即服务 (IaaS) 环境中的任何虚拟机上。使用人工智能方法来优化计算中的负载平衡可能会有效地捕获地理处理的异构计算特征。然而，这种方法更适合具有微调预测模型的常用产品。如果在特定分析功能中对 CI 进行 AI 评估的训练成本过高，则与矢量切片分析等复杂计算相比，在地图代数运算等简单计算中，基于切片编号的直接切片传播可能更可取。

GeoCube 证明了所提出的方法在 Landsat、Gaofen、Sentinel 和 OSM 上的适用性。目前正在测试和支持其他 EO 数据源，未来的工作将将该系统扩展到省级 EO 数据中心。对 GeoCube 和 ODC 进行了性能比较，GeoCube 在数据处理效率方面优于 ODC。在实验中，ODC 使用 NetCDF 格式进行数据存储，该格式因其在云环境中的能力有限而闻名。云优化的 GeoTIFF (COG) 是云环境 (COG 2021) 的替代影像数据格式，ODC 用户正在尝试使用此格式来提高性能。基于 COG 的 ODC 与 GeoCube 的比较可以构成我们未来工作的一个方面。

具有不同空间和时间分辨率的多源数据的对齐是一个挑战，这通常需要重新采样、重新投影以及各种预处理步骤，例如辐射和几何校正。因此，建议使用 ARD 作为 EO 数据立方体的输入。ARD 是目前 EO 领域卫星图像数据产品的流行术语。它通常被定义为经过一系列预处理操作后的一类产品 (Killough 等人, 2020)。作为多源地理空间立方体基础设施，GeoCube 包含卫星图像数据以及矢量和表格数据。目前，还没有矢量和表格 ARD 的定义。

根据这项工作的经验，可以从数据生产和计算的角度提出 ARD 的定义。在数据生产方面，矢量和表格 ARD 意味着数据在完整性、一致性和准确性方面得到了不同程度的质量保证。从计算的角度来看，矢量和表格 ARD 需要以高性能、空间对齐的形式进行组织，例如平铺和使用 COG 等格式。

GeoCube 内核 API 仍然是一个临时接口 (例如 QueryParams)，互操作性是数据立方体社区中的一个问题。OGC Testbed-17 目前正在探索确定地理数据立方体 (GDC) 的中立定义，并开发 Web API 以实现方便、可互操作的 GDC 访问和利用 (OGC 2021)。此外，CEOS 建议在哥伦比亚和瑞士等多个国家使用 ODC，以缓解互操作性问题 (CEOS 2021)。第 1878 章

维度数据立方体，WCS 可以支持切片和修剪等立方体操作 (Baumann 2018)。数据立方体仍在开发中，我们正在探索新的想法来提高其互操作性。

6 结论和未来工作

这项研究提出了用于大地理空间数据分析的立方体基础设施。该基础设施可容纳多源地理空间数据，包括栅格和矢量数据。设计了立方体数据模型，并形式化了产品、空间、时间和带维度四个维度。已经提出了立方体探索的几个例子。该基础设施支持使用混合并行方法进行大规模分析。设计了一组分布式立方体对象，扩展了立方体瓦片的 Spark RDD。分布式立方体对象与多种数据源兼容，包括栅格和矢量数据。为了进一步提高数据处理效率，采用多线程计算方法与云计算一起形成混合并行。批量计算也被用来解决大量瓦片无法同时加载到内存中的问题。

此外，基于机器学习的方法被集成到立方体中以增强并行地理处理。可以提前预测瓦片的 CI 并将其保存在数据库中，从而消除常用产品即时 CI 预测的额外时间成本。

已经概述了称为 GeoCube 的立方体基础设施的设计和实现。它涵盖了立方体中多源地理空间数据的摄取和管理、沿不同立方体维度的地理空间数据查询和访问以及大规模地理空间数据集的高性能立方体计算。这种地理空间数据立方体的开发有助于推进 EO 数据立方体方法，并保持与 BI 立方体的联系。给出了数据查询和访问、数据处理和负载均衡的性能。

结果证明了 GeoCube 基础设施的优势。已经提出了多种应用，包括立方体 OLAP 操作、大规模时间序列分析和多源数据立方体分析。Landsat、高分、OSM 上的结果证明了 GeoCube 的适用性。

数据立方体基础设施仍在开发中，并且由于其在对地观测数据管理和处理方面的潜力而受到越来越多的关注。除了互操作性之外，未来还应该研究以下问题：（1）

离散全局网格系统 (DGGS) 有望成为栅格和矢量数据处理高效的切片网格（Purss 等人，2019）。为了更有效地处理立方体，研究这种平铺机制是值得的。（2）在本研究中，人工智能仅限于提高立方体处理性能。人们已经开展了利用人工智能来优化数据索引的工作，例如学习索引（Kraska et al. 2018）。

这个以后可以探索一下，优化 cube 的数据索引。（3）目前的立方体分析仍然局限于传统的分析函数。深度学习分析已在地理空间领域得到广泛研究。有必要探索如何将深度学习框架纳入立方体基础设施中，以实现基于《国际地理信息科学杂志》1879 的更快的模型训练和数据推理

立方体能力。因此，可以在组织良好的立方体基础设施中提供用于对象检测、场景分类和变化检测的智能解释模型。（4）ARD 是当前立方体中传统分析的主要数据形式，AI 训练数据是深度学习的另一种数据形式。因此，探索一种新的人工智能就绪数据形式来推广立方体基础设施是有价值的。除了这两类就绪数据之外，决策者使用的决策就绪数据也很重要，这些数据通常是通过涉及 ARD、Already 数据和分析模型的工作流程得出的。例如，决策者可能需要有关只能由特殊车辆通行的被洪水淹没的道路的支持信息。此类信息可以使用 ARD 导出作为决策就绪数据，例如地形和洪水计。决策就绪数据还可以集成到当前立方体中，形成三就绪数据（即 ARD、

AI 就绪数据和决策就绪数据) 地理空间基础设施。这样的立方体基础设施将促进 EO 领域当前范式(即 ARD 处理)的发展。

致谢我们感谢 Jennifer Miller 教授和三位审稿人提出的建设性意见, 这些意见有助于提高论文的质量。该工作得到国家自然科学基金(No.42090011 和 No.42071354)和湖北省重大科技项目(No.2020AAA004)的支持。

披露声明 作者未报告任何潜在的利益冲突。基金资助 本工作得到国家自然科学基金项目资助[No. 42090011 和 42071354], 以及湖北省重点研发计划[No. 2020AAA004]。

贡献者注释 高帆是一名博士。武汉大学遥感与信息工程学院学生。他的研究兴趣是高性能地理处理和 GIS。他对本文的想法、研究设计、方法、实施和手稿写作做出了贡献。

彭越, 武汉大学教授。现任湖北省智能地理处理工程中心主任、地理空间信息与位置服务研究所所长。他监督了这项研究, 并对本文的想法、研究设计、方法论和手稿写作做出了贡献。

曹志鹏, 博士。武汉大学遥感与信息工程学院学生。他的研究兴趣是大型时空数据存储。他对这个想法、方法论和实施做出了贡献。

赵帅峰, 博士。武汉大学遥感与信息工程学院学生。他的研究兴趣是大型时空数据存储和处理。他对这个想法、方法论和实施做出了贡献。

第 1880 章

上官博一, 博士。武汉大学遥感与信息工程学院学生。他的研究兴趣是高性能地理处理和 GIService。他对这个想法、方法论和实施做出了贡献。

蒋良存, 武汉大学遥感与信息工程学院副研究员。他的研究兴趣包括对地观测数据基础设施、数据来源和地理空间语义网。他对这个想法、研究设计和方法做出了贡献。

胡磊, 武汉大学遥感与信息工程学院博士后研究员。他的研究兴趣包括对地观测科学和系统、地理空间互操作性和标准以及农业和灾害管理中的环境建模。他对这个想法、研究设计和方法做出了贡献。

方哲是一名博士。武汉大学遥感与信息工程学院学生。他的研究兴趣是灾害应急响应。他对这个想法、方法论和实施做出了贡献。

梁哲恒, 南方数字科技股份有限公司总工程师, 现任《地理信息世界》杂志特约审稿人, 广东省综合评价专家库专家。他对这个想法、研究设计和方法做出了贡献。

ORCID Peng Yue <http://orcid.org/0000-0003-3006-4542> 数据和代码可用性声明 支持本研究结果的数据和代码可在 <https://doi.org/10.6084/m9.figshare.15032847> 中获取。

参考文献 Baumann, P., 2017。datacube 宣言 [在线]。欧盟地球服务器。来源：<https://earthserver.eu/tech/datacube-manifesto/The-Datacube-Manifesto.pdf> [2021 年 7 月 22 日访问]。

Baumann, P., 2018。Datacube 标准及其对分析就绪数据的贡献。时间：2018 年 IEEE 国际地球科学与遥感研讨会 (IGARSS), 2018 年 7 月 22 日至 27 日, 巴伦西亚。

纽约：IEEE, 2051 –2053。鲍曼, P., 等人。 , 1999。用 RasDaMan 进行时空检索。见：第 25 届超大型数据库国际会议记录, 1999 年 9 月 7 日至 10 日在爱丁堡。伯灵顿：

摩根·考夫曼, 746 – 749。鲍曼, P., 等人。 , 2016。地球科学大数据分析：EarthServer 方法。国际数字地球杂志, 9 (1), 3 –29。鲍曼, P., 等人。 , 2018。 , 通过 Datacube 分析促进跨学科地球科学。在：P.P. Mathieu 和 C. Aubrecht, 编辑。对地观测开放科学和创新。

瑞士：Springer Cham, 91 –199。贝里克, S., 等人。 , 2009。Giovanni: 基于 Web 服务 workflows 的数据可视化和分析系统。IEEE 地球科学与遥感学报, 47 (1), 106 –113。

比蒙特, S., 等人。 , 2010。当空间分析遇到 OLAP: 多维模型和运算符。国际数据仓储和挖掘杂志, 6 (4), 33 –60。CEOS, 2021。开放数据立方体[在线]。首席执行官。来源：<https://www.opendatacube.org/ceos> [访问日期：2021 年 7 月 22 日]。

《国际地理信息科学杂志》1881

参考文献

Baumann, P., 2017. The datacube manifesto [online]. EU EarthServer. Available from: <https://earth-server.eu/tech/datacube-manifesto/The-Datacube-Manifesto.pdf> [Accessed 22 July 2021].

Baumann, P., 2018. Datacube standards and their contribution to analysis-ready data. In : 2018 IEEE international geoscience and remote sensing symposium (IGARSS), 22 –27 July 2018 Valencia. New York: IEEE, 2051 –2053.

Baumann, P., et al. , 1999. Spatio-temporal retrieval with RasDaMan. In : Proceedings of 25th international conference on very large data bases, 7 –10 September 1999 Edinburgh. Burlington:

Morgan Kaufmann, 746 –749.

Baumann, P., et al. , 2016. Big data analytics for earth sciences: the EarthServer approach. International Journal of Digital Earth , 9 (1), 3 –29.

Baumann, P., et al. , 2018., Fostering Cross-Disciplinary Earth Science Through Datacube Analytics. In : P.P. Mathieu and C. Aubrecht, eds. Earth observation open science and innovation . Switzerland: Springer Cham, 91 –199.

- Berrick, S., et al. , 2009. Giovanni: a web service workflow-based data visualization and analysis system. *IEEE Transactions on Geoscience and Remote Sensing* , 47 (1), 106 –113.
- Bimonte, S., et al. , 2010. When spatial analysis meets OLAP: multidimensional model and operators. *International Journal of Data Warehousing and Mining* , 6 (4), 33 –60.
- CEOS, 2021. Open Data Cube [online]. CEOS. Available from: <https://www.opendatacube.org/ceos> [Accessed 22 July 2021].
- Cesium, 2021. The Platform for 3D Geospatial [online]. Cesium GS, Inc. Available from: <https://cesium.com> [Accessed 22 July 2021].
- Chaudhuri, S., and Dayal, U., 1997. An overview of data warehousing and OLAP technology. *ACM SIGMOD Record* , 26 (1), 65 –74.
- COG, 2021. Cloud Optimized Geotiff [online]. Cloud Optimized GeoTIFF community. Available from: <https://www.cogeo.org> [Accessed 26 October 2021].
- Damiani, M.L., and Spaccapietra, S., 2008. Spatial data warehouse modelling. In: J. Wang, ed. *Data warehousing and mining: concepts, methodologies, tools, and applications*. Hershey: IGI Global, 659 –678.
- Dask, 2021. Scalable analytics in Python [online]. NumFOCUS community. Available from: <https://dask.org> [Accessed 22 July 2021].
- ESA, 2012. Grid processing on demand (G-POD) for earth observation applications [online]. European Space Agency (ESA). Available from: <https://gpod.eo.esa.int> [Accessed 26 October 2021].
- ESDC, 2021. Earth system data cube [online]. The Earth System Data Cube (ESDC) Team. Available from: <https://cablab.readthedocs.io/en/latest> [Accessed 22 July 2021].
- George, L., 2011. *HBase: the definitive guide: random access to your planet-size data* . California: O'Reilly Media Inc.
- Geotrellis, . 2021. A geographic data processing engine for high performance applications [online]. Azavea Inc. Available from: <https://geotrellis.readthedocs.io/en/latest> [Accessed 22 July 2021].
- Giuliani, G., et al. , 2017. Building an earth observations data cube: lessons learned from the Swiss Data Cube (SDC) on generating analysis ready data (ARD). *Big Earth Data* .,1(1 –2), 100–117.
- Gomes, V.C.F., et al. , 2021. Accessing and processing Brazilian earth observation data cubes with the open data cube platform. *ISPRS Annals of the Photogrammetry, Remote Sensing and Spatial Information Sciences* , V-4-2021, 153 –159.
- Gorelick, N., et al. , 2017. Google earth engine: planetary-scale geospatial analysis for everyone. *Remote Sensing of Environment* , 202, 18 –27.
- Gray, J., et al. , 1997. Data cube: a relational aggregation operator generalizing group-by, cross-tab, and sub-totals. *Data Mining and Knowledge Discovery* , 1 (1), 29 –53.
- Han, J., et al. , 1998. Selective materialization: An efficient method for spatial data cube construction. In : *Pacific-Asia conference on knowledge discovery and data mining*, 15 –17 April 1998. Australia. Berlin: Springer, 144 –158.
- Jupyter, 2021. Project Jupyter [online]. Jupyter community. Available from: <https://jupyter.org> [Accessed 22 July 2021].
- Kasprzyk, J.P., and Devillet, G., 2021. A data cube metamodel for geographic analysis involving heterogeneous dimensions. *ISPRS International Journal of Geo-Information* , 10 (2), 87.
- Killough, B., et al. , 2020. Advancements in the open data cube and analysis ready data —past, present and future. In : *2020 IEEE international geoscience and remote sensing symposium (IGARSS)*,16 –26 July 2018. Waikoloa Village, New York: IEEE, 3373 –3375.

- Kimball, R., and Ross, M., 2011. The data warehouse toolkit: the complete guide to dimensional modeling. New York: John Wiley & Sons Inc.
- Koperski, K., et al. , 1998. Mining knowledge in geographical data. Communications of the ACM , 26 (1), 65 –74.
- Kopp, S., et al. , 2019. Achieving the full vision of earth observation data cubes. Data, 4 (3), 94.
- Kraska, T., et al. , 2018. The case for learned index structures. In: Proceedings of the 2018 inter- national conference on management of data, 10 –15 June 2018. Houston, New York: ACM Digital Library, 489 –504.
- Lewis, A., et al. , 2016. Rapid, high-resolution detection of environmental change over continental scales from satellite data –the earth observation data cube. International Journal of Digital Earth, 9 (1), 106 –111.
- Lewis, A., et al. , 2017. The Australian geoscience data cube —foundations and lessons learned. Remote Sensing of Environment , 202 (1), 276 –292.
- Lewis, A., et al. , 2018. CEOS analysis ready data for land (CARD4L) Overview. In: IEEE international geoscience and remote sensing symposium (IGARSS), 22 –27 July 2018. Valencia, New York: IEEE, 7407–7410.
- LLNL, 2021. Introduction to Parallel Computing Tutorial [online]. Lawrence Livermore National Laboratory (LLNL). Available from: <https://hpc.llnl.gov/training/tutorials/introduction-parallel-computing-tutorial> [Accessed 22 July 2021]
- Mahecha, M.D., et al. , 2020. Earth system data cubes unravel global multivariate dynamics. Earth System Dynamics , 11 (1), 201 –234.
- Momjian, B., 2001. PostgreSQL: introduction and concepts . New York: Addison-Wesley.
- Mueller, N., et al. , 2016. Water observations from space: mapping surface water from 25 years of Landsat imagery across Australia. Remote Sensing of Environment , 174 (1), 341 –352.
- Nativi, S., et al. , 2017. A view-based model of data-cube to support big earth data systems inter- operability. Big Earth Data. ,1(1 –2), 75 –99.
- OGC, 2021. Testbed-17. OGC testbed initiative [online]. OGC. Available from: https://portal.ogc.org/files/?artifact_id=95726 [Accessed 22 July 2021].
- Patel, J.M., and DeWitt, D.J., 1996. Partition based spatial-merge join. ACM SIGMOD Record ,2 5 (2), 259 –270.
- Pedregosa, F., et al. , 2011. Scikit-learn: machine learning in Python. Journal of Machine Learning Research, 12 (10), 2825 –2830.
- Purss, M.B.J., et al. , 2019. Datacubes: a discrete global grid systems perspective. Cartographica, 54 (1), 63 –71.
- Rasdaman, 2021. Raster data manager [online]. Rasdaman GmbH. Available from: <http://rasda-man.com> [Accessed 22 July 2021].
- Rivest, S., et al. , 2001. Toward better support for spatial decision making: defining the character- istics of spatial on-line analytical processing (SOLAP). Geomatica, 55 (4), 539 –555.
- Schramm, M., et al. , 2021. The openeo api –harmonising the use of earth observation cloud serv- ices using virtual data cube functionalities. Remote Sensing , 13 (6), 1125.
- Silva, J.D., et al. , 2008. A set of aggregation functions for spatial measures. In : Proceedings of the ACM 11th international workshop on Data warehousing and OLAP, 30 October. Napa Valley, New York: ACM Digital Library, 25 –32.
- Spring Boot, 2021. Spring [online]. VMware, Inc. Available from: <https://spring.io/projects/spring-boot> [Accessed 22 July 2021].
- Strobl, P., et al. , 2017. The six faces of the data cube. In : Proceedings of big data from space con- ference, 28 –30 November 2017 . Toulouse. Luxembourg: Publications Office of the European

Union, 28 –30.

Sudmanns, M., et al. , 2019. Big Earth data: disruptive changes in earth observation data management and analysis? International Journal of Digital Earth , 13 (7), 832 –850.

Voidrot, M.F., and Percivall, G., 2020. OGC geospatial coverages data cube community practice.

Vol. 509. In: 11th International symposium on digital earth, 24 –27 September 2019. Florence.

Bristol: IOP Publishing, 012058.

Wagemann, J., et al. , 2018. Geospatial web services pave new ways for server-based on-demand access and processing of big earth data. International Journal of Digital Earth , 11 (1), 7 –25.

White, T., 2012. Hadoop: The definitive guide . California: O'Reilly Media Inc.

Wulder, M.A., and Coops, N.C., 2014. Satellites: make earth observations open access. Nature, 513 (7516), 30 –31.

Xarray, 2021. N-D labeled arrays and datasets in Python [online]. NumFOCUS. Available from: <http://xarray.pydata.org/en/stable> [Accessed 22 July 2021].

Yue, P., et al. , 2010. GeoPW: laying blocks for the geospatial processing web. Transactions in GIS , 14 (6), 755 –772.

Yue, P., et al. , 2016. Recent activities in earth data science. IEEE Geoscience and Remote Sensing Magazine, 4 (4), 84 –89.

Yue, P., et al. , 2020. A machine learning approach for predicting computational intensity and domain decomposition in parallel geoprocessing. International Journal of Geographical Information Science , 34 (11), 2243 –2274.

Zaharia, M., et al. , 2010. Spark: Cluster computing with working sets . In: Proceedings of the 2nd USENIX conference on Hot topics in cloud computing , 22 –25 June 2010, Boston. California: USENIX Association, 10.

Zarr. 2021. Zarr format [online]. MRC Centre for Genomics and Global Health. Available from: <https://zarr.readthedocs.io> [Accessed 22 July 2021].

Zhao, P., et al. , 2012. The geoprocessing web. Computers & Geosciences , 47 (10), 3 –12.

1884 F. GAO ET AL.